LUMIST

路觅教育

数学与统计学学科组

Probability and Inference

概率论与统计推断

Guanxu (Gleason) WANG

Part II. Formula Sheet

第二部分：公式表

2026 年 4 月 19 日修订

目录

1 随机事件与概率 **1**

1.1 概率的基本性质 1

1.2 条件概率相关公式 1

1.3 独立性 1

2 随机变量及其分布 **2**

2.1 基本概念 2

2.1.1 期望的基本性质 2

2.1.2 方差的基本性质 2

2.1.3 协方差的定义与基本性质 2

2.1.4 相关系数的定义与基本性质 3

2.2 常用离散分布 3

2.2.1 0–1 分布 / 伯努利 (Bernoulli) 分布 3

2.2.2 二项 (binomial) 分布 3

2.2.3 泊松 (Poisson) 分布 4

2.2.4 几何 (geometric) 分布 4

2.2.5 负二项 (negative binomial) 分布 4

2.2.6 超几何 (hypergeometric) 分布 5

2.3 常用连续分布 5

2.3.1 均匀 (uniform) 分布 5

2.3.2 指数 (exponential) 分布 5

2.3.3 正态 (normal) 分布 6

2.3.4 标准正态分布 (standard normal) 分布 6

2.3.5 伽马 (gamma) 分布 6

2.3.6 贝塔 (beta) 分布 7

3 多维随机变量及其联合分布 **7**

3.1 离散型多维随机变量 7

3.2 连续型多维随机变量 7

4 连续数据的假设检验 **8**

4.1 单样本情况 8

4.1.1 总体均值 μ 的估计 8

4.1.2 总体方差 σ^2 的估计 9

4.1.3 总体概率 p 的估计 9

4.2 双样本情况 9

4.2.1 总体均值 μ 的估计 9

4.2.2 总体概率 p 的估计 10

LUMIST 路觅教育

4.2.3 总体方差 σ^2 的估计 11
4.3 卡方检验 11
4.3.1 拟合优度检验 (Goodness-of-fit test) 11
4.3.2 独立性检验 (Independence test) 11

5 回归分析 **12**
5.1 一元线性回归模型 12
5.1.1 参数估计: 最小二乘法 12
5.1.2 平方和分解 12
5.1.3 显著性检验 13
5.1.4 置信区间 13
5.2 多元线性回归模型 14
5.2.1 参数估计: 最小二乘法 14
5.2.2 残差估计 15
5.3 多元多重回归模型 15
5.4 方差分析 (Analysis of variance, ANOVA) 16

LUMIST 路觅教育

1 随机事件与概率

1.1 概率的基本性质

- 若事件 $A_1, A_2, \cdots, A_n$ 两两互不相容（互斥），则
$$\Pr(A_1 \cup A_2 \cup \cdots \cup A_n) = \Pr(A_1)\Pr(A_2)\cdots\Pr(A_n).$$
- 减法公式:
$$\Pr(A - B) = \Pr(A) - \Pr(A \cap B), \text{ for } B \subset A.$$
- 加法公式:
$$\Pr(A \cup B) = \Pr(A) + \Pr(B) - \Pr(A \cap B).$$
显然，若事件 A 和 B 互斥，则 $A \cap B = \varnothing$，此时 $\Pr(A \cap B) = 0$.

注. 根据教材不同，

- 并集的概率 $\Pr(A \cup B)$ 有时会写成 $\Pr(A + B)$;
- 交集的概率 $\Pr(A \cap B)$ 一般会写做 $\Pr(AB)$;
- 补集（差集）$\bar{A}$ 还可以写成 A^c，易知 $\Pr(\bar{A}) = 1 - \Pr(A)$.

1.2 条件概率相关公式

- 除法公式（条件概率公式）:
$$\Pr(A \mid B) = \frac{\Pr(A \cap B)}{\Pr(B)}.$$
- 乘法公式:
$$\Pr(A \cap B) = \Pr(A \mid B)\Pr(B).$$
- 全概率公式:
$$\Pr(B) = \Pr(B \mid A_1)\Pr(A_1) + \Pr(B \mid A_2)\Pr(A_2).$$
推广:
$$\Pr(B) = \sum_{i=1}^{n} \Pr(B \mid A_i)\Pr(A_i).$$
- 贝叶斯公式:
$$\Pr(A_j \mid B) = \frac{\Pr(A \cap B)}{\Pr(B)} \xlongequal[\text{全概率公式}]{\text{乘法公式}} \frac{\Pr(B \mid A_j)\Pr(A_j)}{\sum_{i=1}^{n} \Pr(B \mid A_i)\Pr(A_i)}.$$

1.3 独立性

两个事件 A 和 B 是独立的，当且仅当
$$\Pr(A \cap B) = \Pr(A)\Pr(B).$$

2 随机变量及其分布

2.1 基本概念

随机变量类型	离散 (discrete)	连续 (continuous)
概率函数 (pmf/pdf)	$p(x) = \Pr(X = x)$	$f(x)$
分布函数 (cdf)	$F(x) = \Pr(X \leqslant x) = \sum_{k \leqslant x} \Pr(X = k)$	$F(x) = \Pr(X \leqslant x) = \int_{-\infty}^{x} f(x)\,\mathrm{d}x$
期望 (expectation)	$\mathbb{E}[X] = \sum_i x_i \Pr(X = x_i)$	$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x)\,\mathrm{d}x$
二阶矩 (second moment)	$\mathbb{E}[X^2] = \sum_i x_i^2 \Pr(X = x_i)$	$\mathbb{E}[X^2] = \int_{-\infty}^{\infty} x^2 f(x)\,\mathrm{d}x$
方差 (variance)	$\mathrm{Var}[X] = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$	

2.1.1 期望的基本性质

- 线性性质: $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b, \quad a, b \in \mathbb{R}$，即 $\mathbb{E}[b] = b, \quad b \in \mathbb{R}$.
- 可加性: $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] \quad \Rightarrow \quad \mathbb{E}\left[\sum_{i=1}^{n} X_i\right] = \sum_{i=1}^{n} \mathbb{E}[X_i]$.
- 若随机变量 X 与 Y **独立**，则 $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.

2.1.2 方差的基本性质

- 线性性质: $\mathrm{Var}[aX + b] = a^2\mathrm{Var}[X], \quad a, b \in \mathbb{R}$，即 $\mathrm{Var}[b] = 0, \quad b \in \mathbb{R}$.
- 若随机变量 X 与 Y **独立**，则 $\mathrm{Var}[X + Y] = \mathrm{Var}[X] + \mathrm{Var}[Y]$.
  否则 $\mathrm{Var}[X + Y] = \mathrm{Var}[X] + \mathrm{Var}[Y] + 2\mathrm{Cov}[X, Y]$.
- 若随机变量 $X_1, X_2, \cdots, X_n$ 之间**独立**，则 $\mathrm{Var}\left[\sum_{i=1}^{n} X_i\right] = \sum_{i=1}^{n} \mathrm{Var}[X_i]$.

2.1.3 协方差的定义与基本性质

定义

$$\mathrm{Cov}[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y],$$

即“乘积的期望”减“期望的乘积”.

性质

- 方差的第二定义: $\mathrm{Cov}[X,X]=\mathrm{Var}[X]$.
- 线性性质: $\mathrm{Cov}[aX+b,Y]=a\mathrm{Cov}[X,Y]$.
  推广: $\mathrm{Cov}[aX+b,cY+d]=ac\mathrm{Cov}[X,Y]$.
- 可加性: $\mathrm{Cov}[X+Y,Z]=\mathrm{Cov}[X,Z]+\mathrm{Cov}[Y,Z]$.
  推广: $\mathrm{Cov}[X+Y,M+N]=\mathrm{Cov}[X,M]+\mathrm{Cov}[X,N]+\mathrm{Cov}[Y,M]+\mathrm{Cov}[Y,N]$.
- 若随机变量 X 与 Y **独立**，则 $\mathrm{Cov}[X,Y]=0$.
  推论 1: $\mathrm{Cov}[X,Y]=\mathbb{E}[XY]-\mathbb{E}[X]\mathbb{E}[Y]=0 \quad\Rightarrow\quad \mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$.
  推论 2: $\mathrm{Var}[X+Y]=\mathrm{Var}[X]+\mathrm{Var}[Y]$.

2.1.4 相关系数的定义与基本性质

定义

$$\mathrm{Corr}[X,Y]=\rho_{XY}=\frac{\mathrm{Cov}[X,Y]}{\sqrt{\mathrm{Var}[X]}\sqrt{\mathrm{Var}[Y]}}=\frac{\mathrm{Cov}[X,Y]}{\mathrm{SD}[X]\,\mathrm{SD}[Y]}\in[-1,1].$$

性质

- 自相关性: $\mathrm{Corr}[X,X]=\rho_{XX}=1$.
- 有界性: $|\rho_{XY}|\leqslant 1$.

2.2 常用离散分布

2.2.1 0–1 分布 / 伯努利 (Bernoulli) 分布

- 符号表示: $X\sim\mathrm{Bernoulli}(p)$.
- 分布解释: 结果只要 $0,1$ 两种，为 1 的概率为 p，为 0 的概率为 $1-p$.
- 概率函数: $\Pr(X=k)=\begin{cases}p, & k=1,\\ 1-p, & k=0.\end{cases}$
- 期望: $\mathbb{E}[X]=p$.
- 方差: $\mathrm{Var}[X]=p(1-p)$.

2.2.2 二项 (binomial) 分布

- 符号表示: $X\sim\mathrm{Binomial}(n,p)$.
- 分布解释: X 表示 n 次独立重复试验中，成功概率为 p 时的成功次数.
- 概率函数 (pmf): $\Pr(X=k)=\binom{n}{k}p^k(1-p)^{n-k}$

- 期望: $\mathbb{E}[X] = np$.
- 方差: $\mathrm{Var}[X] = np(1-p)$.
- 分布关系: $\mathrm{Binomial}(1, p) \equiv \mathrm{Bernoulli}(p)$.

2.2.3 泊松 (Poisson) 分布

- 符号表示: $X \sim \mathrm{Poisson}(\lambda)$.
- 分布解释: 在某个时间段内，平均发生 λ 次的事件发生 k 次的概率.
- 概率函数 (pmf): $\Pr(X = k) = \dfrac{\lambda^k}{k!} e^{-\lambda}$.
- 期望: $\mathbb{E}[X] = \lambda$.
- 方差: $\mathrm{Var}[X] = \lambda$.

2.2.4 几何 (geometric) 分布

- 符号表示: $X \sim \mathrm{Geometric}(p)$.
- 分布解释: 成功概率为 p 的事件，进行到第 k 次才成功的概率.
- 概率函数 (pmf): $\Pr(X = k) = (1-p)^{k-1} p$.
- 期望: $\mathbb{E}[X] = \dfrac{1}{p}$.
- 方差: $\mathrm{Var}[X] = \dfrac{1-p}{p^2}$.

2.2.5 负二项 (negative binomial) 分布

- 符号表示: $X \sim \text{Neg-Bin}(m, p)$.
- 分布解释: 成功概率为 p 的事件，进行到第 k 次正好成功 m 次的概率 (有争议).
- 概率函数 (pmf): $\Pr(X = k) = \dbinom{k-1}{m-1} p^m (1-p)^{k-m}$.
- 期望: $\mathbb{E}[X] = \dfrac{m}{p}$.
- 方差: $\mathrm{Var}[X] = \dfrac{m(1-p)}{p^2}$.
- 分布关系: $\text{Neg-Bin}(1, p) \equiv \mathrm{Geometric}(p)$

2.2.6 超几何 (hypergeometric) 分布

- 符号表示: $X \sim \text{Hyper-Geo}(N, K, n)$.
- 分布解释: 假定在 N 件产品中有 K 件劣品, 随机抽查 n 个, 发现 k 件劣品的概率.
- 概率函数 (pmf): $\Pr(X = k) = \dfrac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}}$.
- 期望: $\mathbb{E}[X] = n\dfrac{K}{N}$.
- 方差: $\text{Var}[X] = n\dfrac{K}{N}\dfrac{N-K}{N}\dfrac{N-n}{N-1}$.

2.3 常用连续分布

2.3.1 均匀 (uniform) 分布

- 符号表示: $X \sim \text{Uniform}(a, b)$.
- 分布解释: 在区间 (a, b) 上抽取任一样本的概率相同.
- 概率函数 (pdf): $f(x) = \dfrac{1}{b-a} \quad (a < x < b)$.
- 分布函数 (cdf): $F(x) = \begin{cases} 0, & x \leqslant a, \\ \dfrac{x-a}{b-a}, & a < x < b, \\ 1, & x \geqslant b. \end{cases}$.
- 期望: $\mathbb{E}[X] = \dfrac{a+b}{2}$.
- 方差: $\text{Var}[X] = \dfrac{(b-a)^2}{12}$.

2.3.2 指数 (exponential) 分布

- 符号表示: $X \sim \text{Exp}(\lambda)$.
- 分布解释: 描述事件与事件之间的间隔时间的概率分布.
- 概率函数 (pdf): $f(x) = \lambda e^{-\lambda x} \quad (x \geqslant 0)$.
- 分布函数 (cdf): $F(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-\lambda x}, & x \geqslant 0. \end{cases}$.
- 期望: $\mathbb{E}[X] = \dfrac{1}{\lambda}$.
- 方差: $\text{Var}[X] = \dfrac{1}{\lambda^2}$.

2.3.3 正态 (normal) 分布

- 符号表示: $X \sim \mathcal{N}\left(\mu, \sigma^2\right)$.
- 分布解释: 无需解释.
- 概率函数 (pdf): $f(x) = \dfrac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (x \in \mathbb{R})$.
- 分布函数 (cdf): $F(x) = \Pr(X \leqslant x) = \displaystyle\int_{-\infty}^{x} f(x)\ \mathrm{d}x$.
- 期望: $\mathbb{E}[X] = \mu$.
- 方差: $\mathrm{Var}[X] = \sigma^2$.

2.3.4 标准正态分布 (standard normal) 分布

- 符号表示: $Z = \dfrac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$.
- 分布解释: 毋庸置疑.
- 概率函数 (pdf): $\phi(x) = \dfrac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad (x \in \mathbb{R})$.
- 分布函数 (cdf): $\Phi(z) = \Pr(Z \leqslant z) = \displaystyle\int_{-\infty}^{z} \phi(x)\ \mathrm{d}x$.
- 期望: $\mathbb{E}[Z] = 0$.
- 方差: $\mathrm{Var}[Z] = 1$.

2.3.5 伽马 (gamma) 分布

- 符号表示: $X \sim \mathrm{Gamma}(k, \lambda)$.
- 分布解释: 某事件单位时间内发生 λ 次, X 表示其发生 k 次所需时间 (多个指数分布叠加).
- 概率函数 (pdf): $f(x) = \dfrac{\lambda^k x^{k-1} \mathrm{e}^{-\lambda x}}{\Gamma(k)} \quad (x > 0)$.
- 分布函数 (cdf): $F(x) = \Pr(X \leqslant x) = \dfrac{\lambda^k}{\Gamma(k)} \displaystyle\int_0^x x^{k-1} \mathrm{e}^{-\lambda x}\ \mathrm{d}x$.
- 期望: $\mathbb{E}[X] = \dfrac{k}{\lambda}$.
- 方差: $\mathrm{Var}[X] = \dfrac{k}{\lambda^2}$.
- 分布关系: $\mathrm{Gamma}(1, \lambda) \equiv \mathrm{Exp}(\lambda)$.

2.3.6 贝塔 (beta) 分布

- 符号表示: $X \sim \text{Beta}\,(\alpha, \beta)$.
- 分布解释: 成功的支持力度 α 与失败的支持力度 β 共同构成了成功率 X 的分布.
- 概率函数 (pdf): $f(x) = \dfrac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha,\beta)} \quad (0 \leqslant x \leqslant 1)$.
- 分布函数 (cdf): $F(x) = \Pr(X \leqslant x) = \dfrac{1}{B(\alpha,\beta)} \displaystyle\int_0^x x^{\alpha-1}(1-x)^{\beta-1}\,\mathrm{d}x$.
- 期望: $\mathbb{E}\,[X] = \dfrac{\alpha}{\alpha+\beta}$.
- 方差: $\text{Var}\,[X] = \dfrac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$.
- 分布关系 1: 若 $X_1 \sim \text{Gamma}(\alpha, \lambda)$ 和 $X_2 \sim \text{Gamma}(\beta, \lambda)$ 独立, 则 $\dfrac{X_1}{X_1+X_2} \sim \text{Beta}\,(\alpha, \beta)$.
- 分布关系 2: $\text{Beta}\,(1,1) \equiv \text{Uniform}\,(0,1)$.

3 多维随机变量及其联合分布

3.1 离散型多维随机变量

联合分布

$$F_{X,Y}(x,y) = \Pr(X \leqslant x, Y \leqslant y) = \sum_{x_i \leqslant x} \sum_{y_j \leqslant y} \Pr(X = x_i, Y = y_j).$$

边际分布

$$\Pr(X = x_i) = \sum_{j=1}^{n} \Pr(X = x_i, Y = y_j).$$

$$\Pr(Y = y_i) = \sum_{i=1}^{n} \Pr(X = x_i, Y = y_j).$$

条件分布

$$\Pr(X = X_i \mid Y = y_i) = \frac{\Pr(X = x_i, Y = y_j)}{\Pr(Y = y_j)}.$$

3.2 连续型多维随机变量

联合分布

$$F_{X,Y}(x,y) = \Pr(X \leqslant x, Y \leqslant y) = \int_{-\infty}^{x} \int_{-\infty}^{y} f(u,v)\,\mathrm{d}v\,\mathrm{d}u.$$

边际分布

$$F_X(x) = F_{X,Y}(x,\infty) = \int_{-\infty}^{x}\left[\int_{-\infty}^{\infty} f(u,y)\ \mathrm{d}y\right]\ \mathrm{d}u \quad \Rightarrow \quad f_X(x) = \int_{-\infty}^{\infty} f(x,y)\ \mathrm{d}y.$$

$$F_Y(y) = F_{X,Y}(\infty,y) = \int_{-\infty}^{y}\left[\int_{-\infty}^{\infty} f(x,v)\ \mathrm{d}x\right]\ \mathrm{d}v \quad \Rightarrow \quad f_Y(y) = \int_{-\infty}^{\infty} f(x,y)\ \mathrm{d}x.$$

条件分布

$$F_{X|Y}(x|y) = \int_{-\infty}^{x} \frac{f_{X,Y}(u,y)}{f_Y(y)}\ \mathrm{d}u \quad \Rightarrow \quad f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}.$$

$$F_{Y|X}(y|x) = \int_{-\infty}^{y} \frac{f_{X,Y}(x,v)}{f_Y(x)}\ \mathrm{d}v \quad \Rightarrow \quad f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_Y(x)}.$$

4 连续数据的假设检验

本章设定，显著性水平 (significance level) 为 α，则需估计 $1-\alpha$ 概率的置信区间，即 $100(1-\alpha)\%$ confidence interval.

4.1 单样本情况

4.1.1 总体均值 μ 的估计

从总体为 $X \sim \mathcal{N}\left(\mu,\sigma^2\right)$ 的分布抽取独立的 n 个样本 $X_1, X_2, \cdots, X_n$，则样本均值为

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

1. **总体标准差 σ 已知.**

   统计量:

   $$Z = \frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1).$$

   因此，$100(1-\alpha)\%$ confidence interval 为

   $$Z\left(\frac{\alpha}{2}\right) \leqslant \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \leqslant Z\left(1-\frac{\alpha}{2}\right),$$

   即

   $$\mu \in \left[\bar{X} \pm Z\left(1-\frac{\alpha}{2}\right)\cdot\frac{\sigma}{\sqrt{n}}\right],$$

   由于 $Z\left(\frac{\alpha}{2}\right) = -Z\left(1-\frac{\alpha}{2}\right)$.

2. **总体标准差 σ 未知.**

   统计量:

   $$t = \frac{\bar{X}-\mu_0}{s/\sqrt{n}} \sim t_{(n-1)}.$$

因此，$100(1-\alpha)\%$ confidence interval 为

$$t_{(n-1)}\left(\frac{\alpha}{2}\right) \leqslant \frac{\bar{X}-\mu}{s/\sqrt{n}} \leqslant t_{(n-1)}\left(1-\frac{\alpha}{2}\right),$$

即

$$\mu \in \left[\bar{X} \pm t_{(n-1)}\left(1-\frac{\alpha}{2}\right) \cdot \frac{s}{\sqrt{n}}\right].$$

当 $n>30$ 时，$t_{(n-1)}\left(1-\frac{\alpha}{2}\right) \approx Z\left(1-\frac{\alpha}{2}\right)$.

4.1.2 总体方差 σ^2 的估计

无偏样本方差公式:

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2.$$

统计量:

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2} \sim \chi^2_{(n-1)}.$$

因此，$100(1-\alpha)\%$ confidence interval 为

$$\chi^2_{(n-1)}\left(\frac{\alpha}{2}\right) \leqslant \frac{(n-1)s^2}{\sigma^2} \leqslant \chi^2_{(n-1)}\left(1-\frac{\alpha}{2}\right),$$

即

$$\sigma^2 \in \left[\frac{(n-1)s^2}{\chi^2_{(n-1)}\left(1-\frac{\alpha}{2}\right)}, \frac{(n-1)s^2}{\chi^2_{(n-1)}\left(\frac{\alpha}{2}\right)}\right].$$

4.1.3 总体概率 p 的估计

统计量:

$$Z = \frac{\hat{p}-p}{\sqrt{p(1-p)/n}} \sim \mathcal{N}(0,1).$$

因此，$100(1-\alpha)\%$ confidence interval 为

$$Z\left(\frac{\alpha}{2}\right) \leqslant \frac{\hat{p}-p}{\sqrt{p(1-p)/n}} \leqslant Z\left(1-\frac{\alpha}{2}\right),$$

即

$$p \in \left[\hat{p} \pm Z\left(1-\frac{\alpha}{2}\right) \cdot \sqrt{\frac{p(1-p)}{n}}\right].$$

4.2 双样本情况

4.2.1 总体均值 μ 的估计

从总体为 $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ 的分布抽取独立的 n_1 个样本的均值为 $\bar{X}_1$，
从总体为 $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ 的分布抽取独立的 n_2 个样本的均值为 $\bar{X}_2$，则

$$\bar{X}_1 - \bar{X}_2 \sim \mathcal{N}\left(\mu_1-\mu_2, \frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}\right).$$

1. **总体标准差 σ 已知.**

   统计量:

$$Z=\frac{\left(\bar{X}_1-\bar{X}_2\right)-\left(\mu_1-\mu_2\right)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0,1).$$

   因此，$100(1-\alpha)\%$ confidence interval 为

$$Z\left(\frac{\alpha}{2}\right) \leqslant \frac{\left(\bar{X}_1-\bar{X}_2\right)-\left(\mu_1-\mu_2\right)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \leqslant Z\left(1-\frac{\alpha}{2}\right),$$

   即

$$\mu_1-\mu_2 \in \left[\left(\bar{X}_1-\bar{X}_2\right) \pm Z\left(1-\frac{\alpha}{2}\right) \cdot \sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}\right].$$

2. **总体标准差 $\sigma_1=\sigma_2$ 未知.**

   统计量:

$$t=\frac{\left(\bar{X}_1-\bar{X}_2\right)-\left(\mu_1-\mu_2\right)}{s_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} \sim t_{(n_1+n_2-2)},$$

   其中，合并方差 (pooled variance) s_p 为

$$s_p^2=\frac{(n_1-1)s_1^2+(n_2-1)s_2^2}{n_1+n_2-2}.$$

3. **总体标准差 $\sigma_1 \neq \sigma_2$ 未知.**

   统计量:

$$Z=\frac{\left(\bar{X}_1-\bar{X}_2\right)-\left(\mu_1-\mu_2\right)}{\sqrt{\frac{s_1^2}{n_1}+\frac{s_2^2}{n_2}}} \sim t_{(df)},$$

   其中，自由度 df 为

$$df=\frac{\left(\frac{s_1^2}{n_1}+\frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1}+\frac{(s_2^2/n_2)^2}{n_2-1}}.$$

4.2.2 总体概率 p 的估计

统计量:

$$Z=\frac{(\hat{p}_1-\hat{p}_2)-(p_1-p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1}+\frac{p_2(1-p_2)}{n_2}}} \sim \mathcal{N}(0,1).$$

4.2.3 总体方差 σ^2 的估计

在正态假设下，有 $\dfrac{(n_1-1)s_1^2}{\sigma_1^2} \sim \chi^2_{(n_1-1)}$ 与 $\dfrac{(n_2-1)s_2^2}{\sigma_2^2} \sim \chi^2_{(n_2-1)}$，根据 F 分布定义，得到统计量

$$F = \frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2} \sim F_{(n_1-1,n_2-1)}.$$

因此，$100(1-\alpha)\%$ confidence interval 为

$$F_{(n_1-1,n_2-1)}\left(\frac{\alpha}{2}\right) \leqslant \frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2} \leqslant F_{(n_1-1,n_2-1)}\left(1-\frac{\alpha}{2}\right),$$

即

$$\frac{\sigma_1^2}{\sigma_2^2} \in \left[\frac{s_1^2}{s_2^2}\cdot\frac{1}{F_{(n_1-1,n_2-1)}\left(1-\frac{\alpha}{2}\right)}, \frac{s_1^2}{s_2^2}\cdot\frac{1}{F_{(n_1-1,n_2-1)}\left(\frac{\alpha}{2}\right)}\right].$$

4.3 卡方检验

4.3.1 拟合优度检验 (Goodness-of-fit test)

提出假设:

$$H_0: \text{原数据服从某个分布} \quad \text{vs} \quad H_1: \text{原数据不服从某个分布}.$$

检验统计量:

$$\chi^2 = \sum_{i=1}^{n} \frac{(O_i - E_i)^2}{E_i} \sim \chi^2_{(k-m-1)},$$

其中, O_i 为 observation (观测值/样本), E_i 为 expectation (**理论**平均值), k 为分类数量, m 是待估参数的数量. 当 $\chi^2 > \chi^2_{(k-m-1)}(1-\alpha)$ 时, 拒绝 H_0.

4.3.2 独立性检验 (Independence test)

提出假设:

$$H_0: \text{原数据服从某个分布} \quad \text{vs} \quad H_1: \text{原数据不服从某个分布}.$$

检验统计量:

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{(r-1)(c-1)},$$

其中, r 和 c 分别为列联表 (contingency table) 的行 (row) 数和列 (column) 数, 且

$$E_{ij} = \frac{R_i \times C_j}{n},$$

即 E_{ij} 为**该行总数**乘以**该列总数**除以**样本总数**. 类似地, 当 $\chi^2 > \chi^2_{(r-1)(c-1)}(1-\alpha)$ 时, 拒绝 H_0.

LUMIST 路觅教育

5 回归分析

5.1 一元线性回归模型

若真实的一元线性回归模型为

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i,$$

其中, $\epsilon_i \sim \mathcal{N}\left(0, \sigma^2\right)$. 在线性回归模型中, 假设

- 独立性: ϵ_i 相互独立;
- 零均值性: $\mathbb{E}\left[\epsilon_i\right] = 0$;
- 同方差性: $\mathrm{Var}\left[\epsilon_i\right] = \sigma^2$;
- 正态性: 若要做精确的 t, F 推断, 通常还假设 $\epsilon_i \sim \mathcal{N}\left(0, \sigma^2\right)$.

于是有

$$\mathbb{E}\left[y_i\right] = \beta_0 + \beta_1 x_i,$$
$$\mathrm{Var}\left[y_i\right] = \sigma^2.$$

5.1.1 参数估计: 最小二乘法

目标函数:

$$\min\ S(\beta) = \sum_{i=1}^{n} \epsilon_i^2 = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2.$$

分别对 β_0, β_1 求偏导得,

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum\limits_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum\limits_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\sum\limits_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sum\limits_{i=1}^{n} x_i^2 - n\bar{x}^2},$$
$$\hat{\beta}_2 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

5.1.2 平方和分解

$$\left.\begin{array}{ll}
\text{总平方和 (sum of squares total)} & SST = \sum\limits_{i=1}^{n}(y_i - \bar{y})^2 = S_{yy} \\
\text{回归平方和 (sum of squares regression)} & SSR = \sum\limits_{i=1}^{n}(\hat{y}_i - \bar{y})^2 \\
\text{误差平方和 (sum of squares error)} & SSE = \sum\limits_{i=1}^{n}(y_i - \hat{y})^2
\end{array}\right\} SST = SSR + SSE$$

相关系数 (correlation coefficient)

$$r=\frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2\sum_{i=1}^{n}(y_i-\bar{y})^2}}=\frac{\sum_{i=1}^{n}x_iy_i-n\bar{x}\bar{y}}{\sqrt{\left(\sum_{i=1}^{n}x_i^2-n\bar{x}^2\right)\left(\sum_{i=1}^{n}y_i^2-n\bar{y}^2\right)}}\in[-1,1].$$

决定系数 (coefficient of determination)

$$R^2=r^2=\frac{S_{xy}^2}{S_{xx}S_{yy}}=\frac{SSR}{SST}=1-\frac{SSE}{SST}.$$

误差估计

$$\mathrm{Var}\left[\epsilon_i\right]=\sigma^2,$$

其中, σ^2 的无偏估计为

$$\hat{\sigma}^2=\frac{SSE}{n-2}=MSE.$$

5.1.3 显著性检验

假设

$$H_0:\beta_1=0 \text{ v.s. } H_1:\beta_1\neq 0.$$

检验:

1. F-test:

$$F=\frac{SSR}{MSE}=\frac{SSR/1}{SSE/(n-2)}\sim F_{(1,n-2)}.$$

2. t-test:

$$T=\frac{\hat{\beta}_1}{\mathrm{SE}\left[\hat{\beta}_1\right]}\sim t_{(n-2)},$$

其中, $\mathrm{SE}\left[\hat{\beta}_1\right]=\sqrt{\frac{MSE}{S_{xx}}}=\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}=\hat{\sigma}\sqrt{\frac{1}{S_{xx}}}.$

参数误差

$$\mathrm{Var}\left[\hat{\beta}_1\right]=\frac{MSE}{S_{xx}}=\frac{\hat{\sigma}^2}{S_{xx}},$$
$$\mathrm{Var}\left[\hat{\beta}_0\right]=\mathrm{Var}\left[\hat{y}-\hat{\beta}_1\bar{x}\right]=\mathrm{Var}\left[\hat{y}\right]+\bar{x}^2\mathrm{Var}\left[\hat{\beta}_1\right]=\hat{\sigma}^2\left(\frac{1}{n}+\frac{\bar{x}^2}{S_{xx}}\right).$$

5.1.4 置信区间

通式: **估计值** $\pm$ **临界值** $\times$ **标准误差**. 因此, 在 $1-\alpha$ 的显著性水平下,

参数的置信区间

$$\beta_1 : \left[\hat{\beta}_1 \pm t_{(n-2)}\left(1-\frac{\alpha}{2}\right)\cdot\frac{\hat{\sigma}}{\sqrt{S_{xx}}}\right],$$

$$\beta_0 : \left[\hat{\beta}_0 \pm t_{(n-2)}\left(1-\frac{\alpha}{2}\right)\cdot\hat{\sigma}\sqrt{\frac{1}{n}+\frac{\bar{x}^2}{S_{xx}}}\right].$$

非预测时, 给定 x_0 估计值 $\hat{y}_0$ 的置信区间

$$\left[\hat{y}_0 \pm t_{(n-2)}\left(1-\frac{\alpha}{2}\right)\cdot\hat{\sigma}\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}\right].$$

预测时, 给定 $\tilde{x}$ 估计值 $\tilde{y}$ 的预测区间

$$\left[\tilde{y} \pm t_{(n-2)}\left(1-\frac{\alpha}{2}\right)\cdot\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(\tilde{x}-\bar{x})^2}{S_{xx}}}\right].$$

5.2 多元线性回归模型

标准形式

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi} + \epsilon_i.$$

矩阵形式

$$\underset{n\times 1}{\boldsymbol{y}} = \underset{n\times(p+1)}{\boldsymbol{X}}\ \underset{(p+1)\times 1}{\boldsymbol{\beta}} + \underset{n\times 1}{\boldsymbol{\epsilon}},$$

i.e.

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}.$$

性质

- $\mathbb{E}[\boldsymbol{\epsilon}] = 0$; 和
- $\mathrm{Cov}[\boldsymbol{\epsilon}] = \mathbb{E}\left[\boldsymbol{\epsilon}\boldsymbol{\epsilon}^\top\right] = \sigma^2\boldsymbol{I}$.

5.2.1 参数估计: 最小二乘法

目标函数:

$$\min\ S(\boldsymbol{\beta}) = \boldsymbol{\epsilon}^\top\boldsymbol{\epsilon} = (\boldsymbol{y}-\boldsymbol{X}\boldsymbol{\beta})^\top(\boldsymbol{y}-\boldsymbol{X}\boldsymbol{\beta}).$$

对 $\boldsymbol{\beta}$ 求导后令其为 0 (FOC), 解方程, 得

$$\hat{\boldsymbol{\beta}} = \left(\boldsymbol{X}^\top\boldsymbol{X}\right)^{-1}\boldsymbol{X}^\top\boldsymbol{y},$$

其具有性质

$$\mathbb{E}\left[\hat{\boldsymbol{\beta}}\right] = \boldsymbol{\beta} \quad 和 \quad \mathrm{Cov}\left[\hat{\boldsymbol{\beta}}\right] = \sigma^2\left(\boldsymbol{X}^\top\boldsymbol{X}\right)^{-1}.$$

5.2.2 残差估计

$$\hat{\boldsymbol{\epsilon}} = \boldsymbol{y} - \hat{\boldsymbol{y}} = \left[\boldsymbol{I} - \underbrace{\boldsymbol{X}\left(\boldsymbol{X}^\top \boldsymbol{X}\right)^{-1}\boldsymbol{X}^\top}_{\text{hat matrix}}\right]\boldsymbol{y} = (\boldsymbol{I} - \boldsymbol{H})\,\boldsymbol{y},$$

其具有性质

$$\mathbb{E}\left[\hat{\boldsymbol{\epsilon}}\right] = \boldsymbol{0} \quad \text{and} \quad \operatorname{Cov}\left[\hat{\boldsymbol{\epsilon}}\right] = \sigma^2\left(\boldsymbol{I} - \boldsymbol{H}\right).$$

5.3 多元多重回归模型

$$\underset{n\times m}{\boldsymbol{Y}} = \underset{n\times(r+1)}{\boldsymbol{X}}\ \underset{(r+1)\times m}{\boldsymbol{\beta}} + \underset{n\times m}{\boldsymbol{\epsilon}},$$

其中

$$\underset{n\times m}{\boldsymbol{Y}} = \begin{bmatrix} Y_{11} & Y_{12} & \cdots & Y_{1m} \\ Y_{21} & Y_{22} & \cdots & Y_{2m} \\ \vdots & \vdots & & \vdots \\ Y_{n1} & Y_{n2} & \cdots & Y_{nm} \end{bmatrix} = \begin{bmatrix} \boldsymbol{Y}_{(1)} & \boldsymbol{Y}_{(2)} & \cdots & \boldsymbol{Y}_{(m)} \end{bmatrix},$$

$$\underset{n\times(r+1)}{\boldsymbol{X}} = \begin{bmatrix} x_{10} & x_{11} & x_{12} & \cdots & x_{1r} \\ x_{20} & x_{21} & x_{22} & \cdots & x_{2r} \\ \vdots & \vdots & \vdots & & \vdots \\ x_{n0} & x_{n1} & x_{n2} & \cdots & x_{nr} \end{bmatrix},$$

$$\underset{(r+1)\times m}{\boldsymbol{\beta}} = \begin{bmatrix} \beta_{01} & \beta_{02} & \cdots & \beta_{0m} \\ \beta_{11} & \beta_{12} & \cdots & \beta_{1m} \\ \beta_{21} & \beta_{22} & \cdots & \beta_{2m} \\ \vdots & \vdots & & \vdots \\ \beta_{r1} & \beta_{r2} & \cdots & \beta_{rm} \end{bmatrix} = \begin{bmatrix} \boldsymbol{\beta}_{(1)} & \boldsymbol{\beta}_{(2)} & \cdots & \boldsymbol{\beta}_{(m)} \end{bmatrix},$$

$$\underset{n\times m}{\boldsymbol{\epsilon}} = \begin{bmatrix} \epsilon_{11} & \epsilon_{12} & \cdots & \epsilon_{1m} \\ \epsilon_{21} & \epsilon_{22} & \cdots & \epsilon_{2m} \\ \vdots & \vdots & & \vdots \\ \epsilon_{n1} & \epsilon_{n2} & \cdots & \epsilon_{nm} \end{bmatrix} = \begin{bmatrix} \boldsymbol{\epsilon}_{(1)} & \boldsymbol{\epsilon}_{(2)} & \cdots & \boldsymbol{\epsilon}_{(m)} \end{bmatrix},$$

具有性质

$$\mathbb{E}\left[\boldsymbol{\epsilon}\right] = \boldsymbol{0} \quad \text{和} \quad \operatorname{Cov}\left[\boldsymbol{\epsilon}_{(i)}, \boldsymbol{\epsilon}_{(k)}\right] = \sigma_{ik}^2 \boldsymbol{I}.$$

因此，我们可以简化成若干**多元线性回归模型**，即

$$\boldsymbol{Y}_{(i)} = \boldsymbol{X}\boldsymbol{\beta}_{(i)} + \boldsymbol{\epsilon}_{(i)}, \quad i = 1, 2, \cdots, m,$$

且 $\operatorname{Cov}\left[\boldsymbol{\epsilon}_{(i)}\right] = \sigma_{ii}^2 \boldsymbol{I}$.

5.4 方差分析 (Analysis of variance, ANOVA)

理论内容在此不过多赘述. 我们仅需清楚 ANOVA 是用来比较两个模型的手段即可，即在 Model 1 的基础上增加若干变量得到 Model 2 后是否更优.

$$\begin{aligned}\text{Model 1:}\quad & Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_r X_r,\\ \text{Model 2:}\quad & Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_r X_r + \beta_{r+1} X_{r+1} + \cdots + \beta_s X_s.\end{aligned}$$

此时，假设检验为:

$$\begin{aligned}H_0 :\ & \begin{pmatrix}\beta_{r+1} & \beta_{r+2} & \cdots & \beta_s\end{pmatrix}^\top = \mathbf{0}\ (\text{每个变量都没有作用});\ \text{vs.}\\ H_1 :\ & \begin{pmatrix}\beta_{r+1} & \beta_{r+2} & \cdots & \beta_s\end{pmatrix}^\top \neq \mathbf{0}\ (\text{至少一个变量有作用}).\end{aligned}$$

ANOVA 的 R code 为`anova(model_1, model_2)`，若其 p-value $< \alpha$，则拒绝 H_0，即在控制了 $X_1, \cdots, X_r$ 的影响之后，解释变量 $X_{r+1}, \cdots, X_s$ 对响应变量 Y 仍然具有显著的线性影响；也就是说，把 $X_{r+1}, \cdots, X_s$ 加入模型可以显著提高对 Y 的拟合.

[0]文至于此, 编者水平有限, 建议或意见请进入编者个人主页联系: [English version], [中文主页].